

Detecção de células fotovoltaicas defeituosas a partir de imagens de eletroluminescência usando redes neurais convolucionais

1st Brenda Silva de Alencar
Universidade Federal da Bahia (UFBA)
Salvador, Brasil
brenda.s1602@outlook.com

Abstract—A energia fotovoltaica representa uma parte significativa da matriz elétrica brasileira. A inspeção de módulos fotovoltaicos é uma prática crucial para maximizar a eficiência dos sistemas solares. O ensaio de eletroluminescência é uma técnica não-destrutiva amplamente utilizada para detectar defeitos em células fotovoltaicas, mas a revisão manual de centenas de imagens compromete a eficiência. Este trabalho propõe um modelo baseado em rede neural convolucional (CNN) para classificar células como defeituosas ou não. O modelo foi treinado com um conjunto de dados de imagens de eletroluminescência, pré-processadas e rotuladas. O modelo alcançou uma acurácia de 82.75%, mas apresentou uma baixa taxa de recall (68%),

Index Terms—Rede Neural Convolucional, Ensaio de Eletroluminescência, Células Fotovoltaicas, Detecção de Defeitos.

I. INTRODUCTION

A energia fotovoltaica representa 19% da matriz elétrica brasileira, de acordo com a Associação Brasileira de Energia Solar Fotovoltaica (Absolar) [1]. A eficiência de sistemas de energia solar é comumente afetada pela presença de defeitos nas células fotovoltaicas, como fissuras, áreas inativas, e *grid-lines*. Sendo assim, a inspeção dos módulos é imprescindível para obter-se um maior aproveitamento dos ativos.

O ensaio de eletroluminescência em módulos fotovoltaicos tem sido amplamente utilizado como ferramenta na detecção de defeitos. Durante o ensaio, o módulo examinado é colocado em ambiente escuro e submetido à uma corrente elétrica direta, com valor semelhante à sua corrente de curto circuito nominal. Em seguida, capturam-se imagens do módulo utilizando uma câmera com sensor de infravermelho capaz de capturar a radiação, normalmente na faixa de 800 a 1150 nm, emitida pelas células [2]. Este método não-destrutivo é eficaz em detectar anomalias que não são reveladas na inspeção visual. Entretanto, neste processo, é necessário que centenas de imagens sejam revisadas por um técnico, o que compromete significativamente a eficiência da inspeção de um grande volume de módulos, como em plantas de energia solar e em linhas de produção em fábricas de módulos fotovoltaicos.

Desde a expansão das técnicas de aprendizado de máquina, o uso dessas tecnologias têm se tornado cada vez mais comum na detecção de defeitos em células fotovoltaicas. A grande

quantidade de dados gerados em um ensaio de eletroluminescência pode ser processada por algoritmos de aprendizado de máquina, que são capazes de identificar padrões em imagens e classificar as células fotovoltaicas como defeituosas ou não. [3] propôs dois modelos para determinar a probabilidade de uma célula estar danificada, o primeiro utiliza a arquitetura Máquina de Vetores de Suporte (SVM) e o segundo usa uma Rede Neural Convolucional (CNN). O primeiro modelo atingiu uma acurácia média de 82.44%, enquanto o segundo atingiu 88.42%. Em trabalhos mais recentes ([3], [4]), são utilizados modelos de segmentação de imagem baseados em aprendizagem profundo de máquina para classificar defeitos e características encontradas das células fotovoltaicas. [3] avaliou a eficácia de x modelos treinados para classificar 24 tipos de defeitos e características em células fotovoltaicas. Dentre os modelos analisados, o DeepLabv3+ obteve o melhor desempenho, obtendo um recall de 86% na identificação de fissuras.

Este trabalho apresenta um modelo para determinar a possibilidade da célula estar danificada utilizando uma arquitetura de rede neural convolucional (CNN). CNNs são amplamente utilizadas em tarefas de classificação e visão computacional, devido a sua capacidade de extrair padrões em imagens [REF IBM]. Esta arquitetura possui três tipos de camadas: convolucional, *pooling* e totalmente conectada. A camada convolucional é o alicerce principal de uma CNN, onde a imagem é processada por filtros (*kernels*) que extraem características da imagem. A camada de *pooling* é utilizada entre as camadas convolucionais a fim reduzir o número de parâmetros da rede. E por fim a camada totalmente conectada, que é responsável por realizar a classificação final. O modelo proposto contém 3 camadas convolucionais, com 32, 32 e 128 filtros, respectivamente. Entre essas camadas, são intercaladas camadas de *pooling* e *dropout*, para evitar o *overfitting* do modelo.

O treinamento do modelo foi realizado com imagens de eletroluminescência de células fotovoltaicas disponibilizadas por [5].

II. DESENVOLVIMENTO

Fig.1 sintetiza a metodologia nas etapas "pré-processamento", metodologia "treinamento" e "predição",

discutidas nas sessões a seguir.

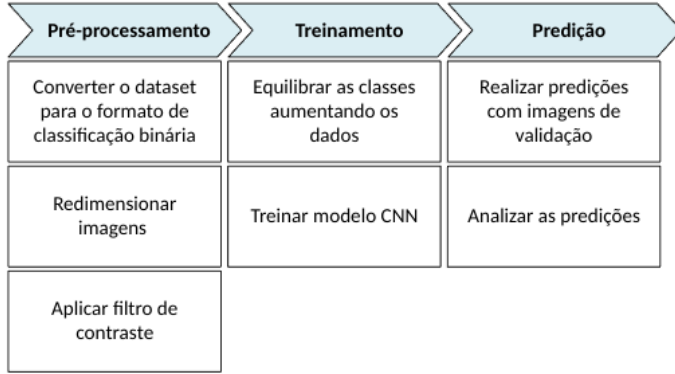


Fig. 1. Example of a figure caption.

A. Pré-processamento

O conjunto de dados fornecido por [5] contém 2.426 imagens de eletroluminescência obtidas de células de painéis solares reais. Cada imagem no dataset contém uma célula individual de silício policristalino ou monocristalino. Todas as imagens foram rotuladas por um especialista, indicando a probabilidade da célula estar danificada. Durante a etapa de pré-processamento, os valores de probabilidade são convertidos em uma classe binária, classificando as imagens como "Defeituosa" ou "Não Defeituosa". Nesse processo imagens rotuladas com probabilidade acima de 60% são categorizadas como "Defeituosa", enquanto aquelas com uma probabilidade igual ou inferior a este limiar são rotuladas como "Não Defeituosa".

As imagens foram redimensionadas para 224x224 pixels. Em seguida, foi aplicado um filtro de equalização de histograma usando a função *createCLAHE* da biblioteca OpenCV, a qual ajusta o contraste da imagem de maneira adaptativa, limitando o aumento de contraste para evitar a ampliação do ruído.

Na Fig.2 são apresentadas quatro amostras do dataset re-classificado.

B. Treinamento

Mesmo após a etapa de pré-processamento, a disposição das classes no dataset estava desbalanceada, pois as células com defeitos representavam apenas 31.3% do total de imagens. Para contornar este problema, foi empregado o método de aumento de dados no conjunto de imagens classificadas como "Defeituosa", com o auxílio da biblioteca. O gráfico na Fig.3 apresenta a disposição final do dataset de referência.

O dataset processado foi dividido de forma randômica em dois conjuntos, um de treinamento com 75% (2845 imagens) e outro de teste com 24% (934 imagens). Os hiperparâmetros do modelo foram definidos empiricamente, com base em experimentos e ajustes realizados durante o processo de desenvolvimento. I.




Fig. 2. Amostras do dataset de células fotovoltaicas: 2(a) monocristalina sem defeito, 2(b) monocristalina com defeito, 2(c) policristalina sem defeito, 2(d) policristalina com defeito. [5]

Distribuição de Imagens de Células Fotovoltaicas por Tipo de Material e Estado




Fig. 3. Distribuição do dataset de referência quanto ao tipo de célula fotovoltaica e o estado.

TABLE I
HIPERPARÂMETROS DO MODELO CNN(24)

Parâmetro	Valor
Tamanho do kernel	3x3
Taxa de aprendizagem	0.001
Number of Epochs	200
Tamanho do lote	14
Função de perda	binary_crossentropy
Otimizador	Adam

C. Predição

Na última etapa, foram realizadas predições com o modelo treinado utilizando um conjunto de 15 imagens. Além disso,

avaliou-se a eficácia do modelo proposto por meio de métricas de avaliação, como acurácia, perda e recall.

III. RESULTADOS

Apesar do número de épocas, definido em 200, o treinamento foi interrompido após 150 épocas, pois o modelo atingiu a convergência. A Fig 4 apresenta a curva de acurácia do modelo durante o treinamento, enquanto a Fig 5 mostra a curva da função de perda. Percebe-se que após a 100ª época, a acurácia de treinamento não apresentou melhorias significativas, enquanto a perda permaneceu faixa de 0.47. A Fig 6 apresenta a acurácia da validação ao longo das épocas, mostrando uma curva com grandes oscilações em uma faixa de 0.55 a 0.82. A acurácia do modelo proposto com o conjunto de teste foi de 82.75%, e perda de 54.10%.

O valor de recall no processo de validação foi de 82,44%, o modelo foi capaz de identificar corretamente a maioria das instâncias positivas. A Fig 7 apresenta a matriz de confusão do modelo, enfatizando que o modelo identificou no conjunto de teste corretamente 93.5% das células não defeituosas e apenas 68% das células defeituosas.




Fig. 4. Acurácia do treinamento ao longo das épocas.




Fig. 5. Perda do treinamento ao longo das épocas.




Fig. 6. Acurácia da validação ao longo das épocas.




Fig. 7. Matriz de confusão para o conjunto de teste.

IV. CONCLUSÃO

A rede neural convolucional proposta neste trabalho alcançou uma acurácia de 82.75% na classificação de células fotovoltaicas defeituosas. No entanto, com base nos resultados apresentados, conclui-se que o modelo não obteve um desempenho satisfatório na classificação de células fotovoltaicas defeituosas, devido a baixa taxa de recall (68%).

Durante a etapa de predição observou-se que o modelo apresentou dificuldade principalmente em classificar principalmente células de silício policristalino. Acredita-se que a textura natural observada nas imagens de eletroluminescência de células policristalinas tenha dificultado a identificação de defeitos pelo modelo.

Para trabalhos futuros, sugere-se o uso da técnica transferência de aprendizagem para melhorar o desempenho do modelo. A técnica de transferência de aprendizagem consiste em utilizar um modelo pré-treinado em um conjunto de dados maior e mais diversificado, como por exemplo o *ImageNet*.

REFERENCES

- [1] A. B. de Energia Solar Fotovoltaica, “Energia solar fotovoltaica no brasil: Infográfico absolar,” Infográfico, aug 2024, disponível em: <https://www.portalsolar.com.br/mercado-de-energia-solar-no-brasil.html>. Acesso em: 4 ago. 2024.
- [2] M. Frazão, J. Silva, K. Lobato, and J. Serra, “Electroluminescence of silicon solar cells using a consumer grade digital camera,” *Measurement*, vol. 99, pp. 7–12, 2017. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0263224116307187>
- [3] L. Pratt, J. Mattheus, and R. Klein, “A benchmark dataset for defect detection and classification in electroluminescence images of pv modules using semantic segmentation,” *Systems and Soft Computing*, vol. 5, p. 200048, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2772941923000017>
- [4] L. Pratt, D. Govender, and R. Klein, “Defect detection and quantification in electroluminescence images of solar pv modules using u-net semantic segmentation,” *Renewable Energy*, vol. 178, pp. 1211–1222, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0960148121009526>
- [5] C. Buerhop, S. Deitsch, A. Maier, F. Gallwitz, S. Berger, B. Doll, J. Hauch, C. Camus, and C. Brabec, “A benchmark for visual identification of defective solar cells in electroluminescence imagery,” *35th European Photovoltaic Solar Energy Conference and Exhibition*, 09 2018.