

Conference Paper Title*

1st Brenda Silva de Alencar
Universidade Federal da Bahia (UFBA)
Salvador, Brasil
brenda.s1602@outlook.com

Abstract—This document is a model and instructions for L^AT_EX. This and the IEEEtran.cls file define the components of your paper [title, text, heads, etc.]. *CRITICAL: Do Not Use Symbols, Special Characters, Footnotes, or Math in Paper Title or Abstract.

Index Terms—component, formatting, style, styling, insert.

I. INTRODUCTION

A utilização de energia solar no Brasil tem crescido nos últimos anos. De acordo com [X] o uso de placas solares está em XX. A eficiência de sistemas de energia solar é comumente afetada pela presença de defeitos nas células fotovoltaicas, como fissuras, áreas inativas, e *gridlines*. Sendo assim, a inspeção dos módulos é imprescindível para obter-se um maior aproveitamento dos ativos.

[Matos] aponta o ensaio de eletroluminescência em módulos fotovoltaicos como uma ferramenta recorrente na detecção de defeitos. Durante o ensaio, o módulo examinado é colocado em ambiente escuro e submetido à uma corrente elétrica direta, com valor semelhante à sua corrente de curto circuito nominal. Em seguida, capturam-se imagens do módulo utilizando uma câmera com sensor de infravermelho capaz de capturar a radiação, normalmente na faixa de 800 a 1150 nm, emitida pelas células (Frazão et al.,2016). Este método não-destrutivo é eficaz em detectar anomalias que não são reveladas na inspeção visual. Entretanto, neste processo, é necessário que centenas de imagens sejam revisadas por um técnico, o que compromete significativamente a eficiência da inspeção de um grande volume de módulos, como em plantas de energia solar e em linhas de produção em fábricas de módulos fotovoltaicos.

Desde a expansão das técnicas de aprendizado de máquina, o uso dessas tecnologias têm se tornado cada vez mais comum na detecção de defeitos em células fotovoltaicas. A grande quantidade de dados gerados em um ensaio de eletroluminescência pode ser processada por algoritmos de aprendizado de máquina, que são capazes de identificar padrões em imagens e classificar as células fotovoltaicas como defeituosas ou não. [Deutsch] propôs dois modelos para determinar a probabilidade de uma célula estar danificada, o primeiro utiliza a arquitetura Máquina de Vetores de Suporte (SVM) e o segundo usa uma Rede Neural Convolucional (CNN). O primeiro modelo atingiu uma acurácia média de 82.44%, enquanto o segundo atingiu 88.42%. Em trabalhos mais recentes ([1],[2]), são utilizados modelos de segmentação de imagem baseados em aprendizagem profundo de máquina para classificar defeitos e

características encontradas das células fotovoltaicas. [3] avaliou a eficácia de x modelos treinados para classificar 24 tipos de defeitos e características em células fotovoltaicas. Dentre os modelos analisados, o DeepLabv3+ e o U-Net obtiveram os melhores resultados, obtendo um recall de 86% e XXX na identificação de fissuras.

Este trabalho apresenta um modelo baseado em aprendizagem de máquina para detecção de células fotovoltaicas defeituosas. O modelo proposto determina a possibilidade da célula estar danificada utilizando uma arquitetura de rede neural convolucional (CNN). O treinamento foi realizado com imagens de eletroluminescência de células fotovoltaicas disponibilizadas por [X].

II. DESENVOLVIMENTO

Fig.1 sintetiza a metodologia nas etapas "pré-processamento", metodologia "treinamento" e "predição", discutidas nas sessões a seguir.

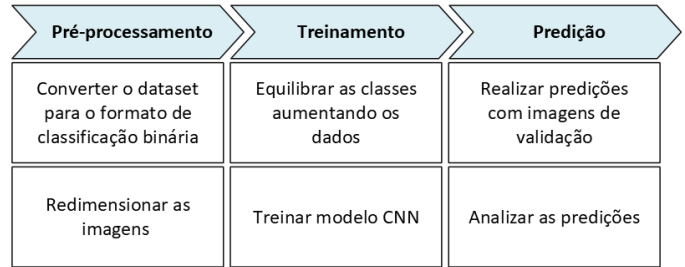


Fig. 1. Example of a figure caption.

A. Pré-processamento

O conjunto de dados utilizado para este trabalho é fornecido por [x]. Este dataset contém 2.426 imagens de eletroluminescência de células de painéis solares reais. Cada imagem no dataset contém uma célula individual de silício policristalino ou monocristalino. Todas as imagens foram rotuladas por um especialista, indicando a probabilidade da célula estar danificada.

Durante a etapa de pré-processamento, os valores de probabilidade são convertidos em uma classe binária, classificando as imagens como "Defeituosa" ou "Não Defeituosa". Nesse processo imagens rotuladas com probabilidade acima de 60% são categorizadas como "Defeituosa", enquanto aquelas com uma probabilidade igual ou inferior a este limiar são rotuladas

como "Não Defeituosa". Em seguida, as imagens foram redimensionadas para 224x224 pixels. Na Fig.2 são apresentadas quatro amostras do dataset reclassificado.




Fig. 2. Amostras do dataset de células fotovoltaicas: 2(a) monocristalina sem defeito, 2(b) monocristalina com defeito, 2(c) policristalina sem defeito, 2(d) policristalina com defeito. [REFER]

Mesmo após este processo, a disposição das classes no dataset estava desbalanceada, pois as células com defeitos representavam apenas 31.3% do total de imagens. Para contornar este problema, foi empregado o método de aumento de dados no conjunto de imagens classificadas como "Defeituosa", com o auxílio da biblioteca XXX. O gráfico na Fig.1 apresenta a disposição final do dataset de referência.

B. Treinamento

O dataset processado foi dividido de forma randômica em dois conjuntos, um de treinamento com 75% (XX imagens) e outro de teste com 24% (XX imagens). Os hiperparâmetros do modelo foram definidos empiricamente, com base em experimentos com um dataset reduzido e ajustes realizados durante o processo de desenvolvimento. Então o modelo proposto, uma rede convolucional, foi treinado a classificar uma célula fotovoltaica como "Defeituosa" ou "Não Defeituosa".

TABLE I
TABLE TYPE STYLES

Table Head	Table Column Head		
	Table column subhead	Subhead	Subhead
copy	More table copy ^a		

^aSample of a Table footnote.

C. Predição

Na última etapa, foram realizadas predições com o modelo treinado utilizando um conjunto de 15 imagens. Além disso, avaliou-se a eficácia do modelo proposto por meio de métricas de avaliação, como acurácia, precisão, recall e F1-score.

III. RESULTADOS

A acurácia do modelo proposto foi de XX%, com uma precisão de XX%, recall de XX%. Fig ?? apresenta a matriz de confusão do modelo, enfatizando que o modelo obteve um bom desempenho na classificação de células fotovoltaicas

IV. CONCLUSÃO

ACKNOWLEDGMENT

The preferred spelling of the word "acknowledgment" in America is without an "e" after the "g". Avoid the stilted expression "one of us (R. B. G.) thanks ...". Instead, try "R. B. G. thanks...". Put sponsor acknowledgments in the unnumbered footnote on the first page.

REFERENCES

Please number citations consecutively within brackets [1]. The sentence punctuation follows the bracket [2]. Refer simply to the reference number, as in [3]—do not use "Ref. [3]" or "reference [3]" except at the beginning of a sentence: "Reference [3] was the first ..."

Number footnotes separately in superscripts. Place the actual footnote at the bottom of the column in which it was cited. Do not put footnotes in the abstract or reference list. Use letters for table footnotes.

Unless there are six authors or more give all authors' names; do not use "et al.". Papers that have not been published, even if they have been submitted for publication, should be cited as "unpublished" [4]. Papers

that have been accepted for publication should be cited as "in press" [5]. Capitalize only the first word in a paper title, except for proper nouns and element symbols.

For papers published in translation journals, please give the English citation first, followed by the original foreign-language citation [6].

REFERENCES

- [1] G. Eason, B. Noble, and I. N. Sneddon, "On certain integrals of Lipschitz-Hankel type involving products of Bessel functions," *Phil. Trans. Roy. Soc. London*, vol. A247, pp. 529–551, April 1955.
- [2] J. Clerk Maxwell, *A Treatise on Electricity and Magnetism*, 3rd ed., vol. 2. Oxford: Clarendon, 1892, pp.68–73.
- [3] I. S. Jacobs and C. P. Bean, "Fine particles, thin films and exchange anisotropy," in *Magnetism*, vol. III, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271–350.
- [4] K. Elissa, "Title of paper if known," unpublished.
- [5] R. Nicole, "Title of paper with only first word capitalized," *J. Name Stand. Abbrev.*, in press.
- [6] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, "Electron spectroscopy studies on magneto-optical media and plastic substrate interface," *IEEE Transl. J. Magn. Japan*, vol. 2, pp. 740–741, August 1987 [Digests 9th Annual Conf. Magnetism Japan, p. 301, 1982].
- [7] M. Young, *The Technical Writer's Handbook*. Mill Valley, CA: University Science, 1989.
- [8] D. P. Kingma and M. Welling, "Auto-encoding variational Bayes," 2013, arXiv:1312.6114. [Online]. Available: <https://arxiv.org/abs/1312.6114>

- [9] S. Liu, “Wi-Fi Energy Detection Testbed (12MTC),” 2023, gitHub repository. [Online]. Available: <https://github.com/liustone99/Wi-Fi-Energy-Detection-Testbed-12MTC>
- [10] “Treatment episode data set: discharges (TEDS-D): concatenated, 2006 to 2009.” U.S. Department of Health and Human Services, Substance Abuse and Mental Health Services Administration, Office of Applied Studies, August, 2013, DOI:10.3886/ICPSR30122.v2
- [11] K. Eves and J. Valasek, “Adaptive control for singularly perturbed systems examples,” Code Ocean, Aug. 2023. [Online]. Available: <https://codeocean.com/capsule/4989235/tree@articlePRATT2023200048>, title = A benchmark dataset for defect detection and classification in electroluminescence images of PV modules using semantic segmentation, journal = Systems and Soft Computing, volume = 5, pages = 200048, year = 2023, issn = 2772-9419, doi = <https://doi.org/10.1016/j.sasc.2023.200048>, url = <https://www.sciencedirect.com/science/article/pii/S2772941923000017>, author = Lawrence Pratt and Jana Mattheus and Richard Klein, keywords = Electroluminescence, EL, PV, Semantic segmentation, Machine learning

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove the template text from your paper may result in your paper not being published.